José Daniel Paz Ortega - 1200022 y Jonathan García - 1045222
Ciencia de Datos
Ingeniero: Max Cerna
Ficha del modelo de abandono, versión 1 3 de noviembre de 2026

Los datos son simulados y no corresponden a ningún operador ni usuario real. Las cifras sirven para el curso y no para tomar decisiones reales.

Qué hace

Estima la probabilidad de que una persona no tenga ningún abordaje válido en los 30 días que empiezan en la fecha de corte, y marca a quién conviene contactar en una campaña de retención.

Datos

Los nueve archivos de la Red Metropolitana, del 1 de junio al 29 de agosto de 2026, cargados con el pipeline del Proyecto 1 hasta Silver. Solo se usan registros válidos, lo que está en cuarentena no entra.

Unidad, población y etiqueta

La unidad es la persona. El número dentro de la tarjeta une Transmetro, Transurbano y MetroRiel, y cada tarjeta de Aerómetro cuenta aparte porque no se puede enlazar. Entran las personas con al menos 2 abordajes en los 28 días antes del corte y sin un DELETE vigente en el padrón. La etiqueta es 1 si no viajan en ningún operador en los 30 días desde el corte.

Features y modelo

Son 19 variables de los 28 días antes del corte: recencia, frecuencia, tendencia, operadores, horario, gasto y perfil. El modelo es un HistGradientBoostingClassifier dentro de un Pipeline de scikit-learn 1.8.0, entrenado con todo el corte A del 1 de julio y con semilla 42. Está guardado en modelos/modelo_abandono_v1.joblib.

Métricas

	PR-AUC	ROC-AUC	Línea base de recencia	Línea base de la tasa
Validación cruzada en el corte A	0.426 ± 0.015	0.841	0.403	0.119
Test único en el corte B	0.386	0.839	0.359	0.110

Umbral

Se contacta a quien tenga un puntaje de 0.325 o más. Contactar cuesta Q5, la campaña retiene al 25% de quienes se iban a ir y cada retenido vale Q60, entonces la ganancia es G = 10 × VP - 5 × FP. En el corte A el umbral dejó Q11,480 con precisión de 0.454 y recall de 0.405. En el corte B dejó Q7,550 con precisión de 0.408 y recall de 0.430. Contactar a todos perdería Q191,030 en el corte A.

Revisión de fugas

Las features solo usan lo que pasó antes de las 00:00 del corte y la etiqueta solo los 30 días siguientes. La prueba de recorte del corte A no dio diferencias ni en Silver ni en los archivos crudos. El ensayo de invariancia con el corte B dio predicciones idénticas con y sin los 30 días siguientes. El corte B se evaluó una sola vez.

Limitaciones

- El enlace entre tarjetas es un supuesto. 1,460 de los 7,095 positivos del corte A son solo de Aerómetro y no se pueden verificar.
- Casi toda la señal está en la recencia. El modelo le gana a la línea base de días sin viajar por 0.023 en validación y por 0.027 en B.
- Si abandona menos gente, como pasó en B, la misma campaña deja menos ganancia.
- Se entrenó con un solo mes, así que no vio vacaciones, temporadas ni cambios de tarifa.
- El 25% de retención es un supuesto del escenario y no algo que se haya medido.

Uso

```
python predecir.py --datos datos_red --fecha-corte 2026-08-30
```

Daniel Paz, 1200022, y Jonathan García, 1045222. Versión 1, 3 de noviembre de 2026.