Ficha del modelo: abandono de la red, v1

Aviso: los datos son simulados. No corresponden a ningún operador ni usuario real; las cifras sirven para el curso, no para decisiones reales.

Qué hace. Estima la probabilidad de que una persona no tenga ningún abordaje válido en los 30 días que empiezan en la fecha de corte, y marca a quién conviene contactar en una campaña de retención.

Datos y periodo. Los nueve archivos de la Red Metropolitana, versión 2, del 1 de junio al 29 de agosto de 2026, cargados con el pipeline del Proyecto 1 hasta la capa Silver (solo registros válidos; lo que está en cuarentena no entra).

Unidad. La persona: el número dentro de la tarjeta vincula Transmetro, Transurbano y MetroRiel. Cada tarjeta de Aerómetro cuenta como persona aparte, porque su llave es un hash que no se puede enlazar.

Población. Personas con al menos 2 abordajes válidos en los 28 días anteriores al corte y sin un DELETE vigente en el CDC antes del corte.

Etiqueta. 1 si no hay ningún abordaje válido, en ningún operador, entre el corte y 30 días después; 0 si hay al menos uno.

Features. 19 variables con una ventana de 28 días antes del corte (recencia, frecuencia, tendencia, mezcla de operadores, horario, gasto y perfil del padrón). Diccionario en diccionario_features.md.

Modelo. HistGradientBoostingClassifier dentro de un Pipeline de scikit-learn 1.8.0, entrenado con todo el corte A (1 de julio). Archivo: modelos/modelo_abandono_v1.joblib. Semilla 42.

Métricas.

	PR-AUC	ROC-AUC	Línea base (recencia)	Línea base (tasa)
Validación cruzada, corte A (5 folds)	0.426 ± 0.015	0.841	0.403	0.119
Test único, corte B	0.386	0.839	0.359	0.110

Umbral y su costo. Se contacta si el puntaje es ≥ 0.325. Escenario: contactar cuesta Q5, la campaña retiene al 25% de quienes se iban a ir y cada retenido vale Q60, así que G = 10 × VP − 5 × FP. El umbral maximiza G en el corte A (Q11,480, precisión 0.454, recall 0.405). En el corte B dejó Q7,550 (precisión 0.408, recall 0.430). Contactar a todos perdería Q191,030 en el corte A.

Fugas revisadas. Las features solo usan eventos anteriores a las 00:00 del corte y la etiqueta solo los 30 días siguientes. Prueba de recorte del corte A: 0 diferencias recortando Silver y recortando los archivos crudos. Prueba de invariancia ensayada con el corte B: predicciones idénticas con y sin los 30 días posteriores. El corte B se usó una sola vez.

Limitaciones.

- El vínculo entre tarjetas es un supuesto. Si dos números iguales fueran personas distintas, se mezclarían; si una persona usa Aerómetro y otro operador, se cuenta dos veces. 1,460 de los 7,095 positivos del corte A (0.206) son solo de Aerómetro y no se pueden verificar.
- Casi toda la señal está en la recencia: el modelo le gana al baseline de días sin viajar por 0.023 de PR-AUC en validación y 0.027 en B.
- La ganancia depende de cuánta gente abandona: en B, con menos abandono, la misma campaña rinde menos.
- Entrenado con un solo mes (junio) para predecir julio: no vio estacionalidad, vacaciones ni cambios de tarifa.
- El efecto de la campaña (25% de retención) es un supuesto del escenario, no algo medido.

Uso. `python predecir.py --datos datos_red --fecha-corte 2026-08-30`. Equipo: Daniel Paz (1200022) y Jonathan García (1045222). Versión v1, 3 de noviembre de 2026.