Ing. Max Cerna
Ciencia de Datos
Segundo semestre 2026



Proyecto 2 - Fase 1

¿Quién deja de usar la red?

José Daniel Paz Ortega
carné: 1200022
Jonathan García
carné: 1045222

3 de noviembre de 2026

Introducción

En este proyecto queremos estimar qué personas van a dejar de usar la red de transporte en los próximos 30 días, para que la Agencia pueda decidir a quién contactar en una campaña de retención. Usamos el mismo pipeline del Proyecto 1 para cargar los datos y sobre eso armamos la etiqueta, las features y los primeros modelos.

Los datos son simulados y no corresponden a ningún operador ni usuario real.

Datos nuevos desde cero

Para cargar todo desde un entorno vacío se corre un solo comando:

```
python orquestacion/flow_prefect.py --desde-cero
```

Este comando borra el lake, el warehouse y lo que dbt genera, carga los nueve archivos de la carpeta datos_red, corre staging, silver y gold con sus pruebas y al final calcula las features de los tres cortes. No hay pasos manuales. dbt crea sus vistas de Bronze al arrancar y no usamos seeds ni tablas incrementales, así que Silver y Gold se recalculan completos cada vez.

Archivo	Filas esperadas	Filas en Bronze	Diferencia
aerometro_boardings.csv	387,053	387,053	0
am_estaciones.csv	14	14	0
cdc_padron_usuarios.csv	77,636	77,636	0
metroriel_viajes.jsonl	590,844	590,844	0
mr_estaciones.csv	22	22	0
tm_estaciones.csv	104	104	0
transmetro_validaciones.csv	713,786	713,786	0
transurbano_transacciones.csv	1,635,788	1,635,788	0
tu_paradas.csv	328	328	0

Los nueve archivos llegaron completos a Bronze, así que no hubo diferencias que explicar. La limpieza de duplicados, nulos, fechas futuras y viajes sin salida pasa después, en Silver, y lo que se rechaza queda en cuarentena.

Estos son los tiempos de una corrida desde cero en nuestra máquina:

Etapa	Segundos
Vaciar lake y warehouse	0.2
Ingesta a Bronze	1.8
dbt run	38.1

Etapa	Segundos
dbt test	16.4
Exportar los CSV del tablero	0.3
Features de los cortes A, B y C	10.3
Total	67.1

Etiqueta, población y unidad

Etiqueta

Una persona tiene etiqueta 1 si no tiene ningún abordaje válido en ningún operador desde las 00:00 del día de corte hasta 30 días después. Si tiene al menos uno, su etiqueta es 0.

Unidad

En el Proyecto 1 dejamos dos niveles de identidad: la tarjeta de cada operador y la persona, con el supuesto de que el número dentro de la tarjeta es el mismo para Transmetro, Transurbano y MetroRiel. Por ejemplo TC-00013132, 0000013132 y MR0013132 serían la misma persona. Si usáramos la tarjeta como unidad, alguien que deja Transmetro pero sigue viajando en Transurbano contaría como abandono, y a esa persona no hace falta contactarla. Por eso trabajamos con la persona. Aerómetro entrega un hash que no se puede enlazar con nada, así que cada tarjeta de Aerómetro cuenta como una persona aparte.

Población

Entra a un corte la persona que tiene al menos 2 abordajes válidos en los 28 días anteriores y que no tiene un DELETE vigente en el padrón antes del corte.

Corte	Fecha	Población	Positivos	Tasa
A	1 de julio de 2026	59,491	7,095	0.1193
B	31 de julio de 2026	58,113	6,387	0.1099
C	30 de agosto de 2026	57,701	oculta	oculta

La tasa sale de dividir los positivos entre la población, por ejemplo 7,095 entre 59,491 da 0.1193 en el corte A.

Costo de la unidad

Lo medimos de dos formas. Primero armamos la misma población y etiqueta pero con la tarjeta como unidad. En el corte A hay 10,812 tarjetas positivas y en 2,404 de ellas la persona siguió viajando con otra tarjeta, o sea 0.222 de los positivos. En el corte B fueron 2,400 de 10,004, que es 0.240. Con la tarjeta, más o menos uno de cada cinco abandonos sería falso.

Lo segundo es lo que nos cuesta usar la persona. Las tarjetas de Aerómetro no se pueden enlazar, así que en el corte A son 10,429 de las 59,491 personas, y 1,460 de los 7,095 positivos son solo de Aerómetro, que es 0.206. Si alguna de esas personas siguió viajando con otra tarjeta, es un abandono falso que no podemos medir. En el corte B fueron 1,360 de 6,387, que es 0.213.

Features a la fecha de corte y auditoría de fuga

El código recibe la fecha de corte como parámetro y calcula los tres cortes con la misma función. Los resultados se apilan en una sola tabla con la fecha de corte como columna, con 175,305 filas en total: 59,491 de A, 58,113 de B y 57,701 de C. La tabla queda en el warehouse y también en un archivo parquet.

Calculamos 19 features con ventanas de 28 días o menos, iguales en los tres cortes. Miden cuántos días lleva la persona sin viajar, cuántos viajes hizo en 7, 14 y 28 días, si viene bajando, cuántos días estuvo activa, qué operadores usa, a qué horas viaja, cuánto gastó y su perfil en el padrón. Todas salen de Silver, así que lo que está en cuarentena no entra. La lista completa está en el diccionario de features del repositorio.

Para revisar que no hubiera fuga hicimos la prueba de recorte. Calculamos las features del corte A con los datos completos y otra vez con los datos cortados al 30 de junio, y comparamos las dos tablas. La hicimos en dos niveles:

Nivel	Qué se recorta	Filas	Diferencias
Silver	Los eventos de Silver y del padrón antes del 1 de julio	59,491	0
Crudo	Los 9 archivos originales, corriendo todo el pipeline en una copia aparte	59,491	0

Ninguna feature tuvo diferencias, así que no hubo que corregir ninguna. El nivel crudo es el más exigente porque también detectaría una fuga dentro del pipeline, por ejemplo una deduplicación que mire datos futuros. En ese nivel un viaje de MetroRiel solo se queda si ya había terminado antes del corte, porque el operador entrega el viaje hasta que se cierra. La prueba se repite con estos comandos:

```
python -m ml.prueba_recorte --nivel silver
python -m ml.prueba_recorte --nivel crudo
```

Línea base y regresión logística regularizada

Como métrica usamos la PR-AUC. Solo el 11.9% de la población del corte A abandona y la Agencia no va a contactar a todos, sino que va a ordenar a las personas por riesgo y empezar por las de arriba. La PR-AUC mide qué tan arriba de esa lista quedan los que se van, y a diferencia de la ROC-AUC no se infla con los miles de negativos fáciles. Además su

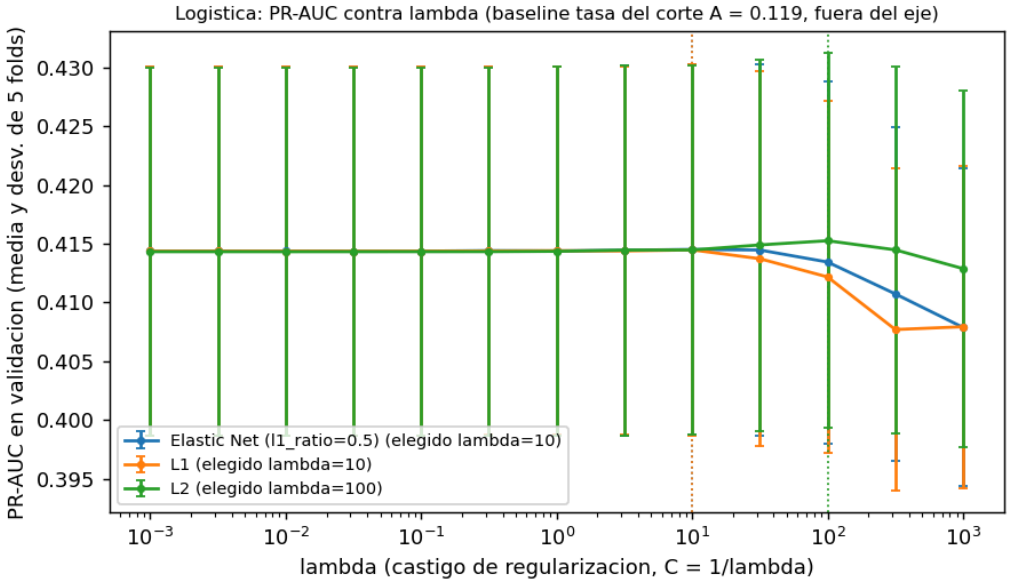
línea base es fácil de leer: un modelo que no sabe nada saca la tasa de positivos, 0.119. La ROC-AUC la reportamos al lado solo como referencia.

Todos los modelos usan los mismos 5 folds estratificados del corte A con semilla 42. La etiqueta del corte B no se usó en esta fase. El escalado y el one-hot del perfil van dentro de un Pipeline, así que se ajustan solo con el fold de entrenamiento.

Modelo	PR-AUC validación	Desviación	ROC-AUC
Línea base 1: a todos la tasa del corte A	0.119	0.000	0.500
Línea base 2: días desde el último viaje	0.403	0.014	0.826
Línea base 3: menos viajes en 28 días	0.254	0.004	0.743
Logística L2, λ = 100	0.415	0.016	0.831
Logística L1, λ = 10	0.414	0.016	0.831
Logística Elastic Net, λ = 10	0.415	0.016	0.831

La línea base 2 no entrena nada, solo ordena a las personas por los días que llevan sin viajar. La elegimos porque dejar de viajar es justo como empieza el abandono. Resultó ser muy fuerte, ya que la logística solo le gana por 0.012, menos que la desviación entre folds. Eso nos dice que casi toda la señal está en la recencia y que lo demás aporta poco.

Para la regularización probamos λ desde 0.001 hasta 1,000 con los tres castigos y elegimos el que dio mayor PR-AUC media en validación: L2 con λ = 100, y L1 y Elastic Net con λ = 10. En scikit-learn 1.8 el tipo de castigo se elige con l1_ratio y la fuerza con C, que es 1 entre λ. Con unas 47,000 filas por fold y 19 features, el resultado casi no cambia hasta λ = 10. De ahí para arriba L1 y Elastic Net empiezan a perder porque mandan a cero coeficientes que sí servían. Los tres castigos quedaron prácticamente empatados.



Estos son los coeficientes que más empujan hacia el abandono, de la logística L2 con λ = 100 entrenada con todo el corte A y con las variables escaladas:

Feature	Coeficiente	Cómo se lee
Días desde el último viaje	+0.764	Cada día de más sin viajar sube el riesgo. Es la señal más fuerte.
Viajes en 28 días	+0.332	Si los viajes de la última semana y los días activos se quedan iguales, tener más viajes en el mes quiere decir que antes viajaba más y ya no.
Perfil general	+0.227	En el corte A abandona el 17.5% de este perfil, contra 11.9% de toda la población.
Perfil estudiante	+0.100	También abandonan más que el promedio, el 15.9%.
Viajes en 14 días	+0.086	Igual que el anterior, viajes concentrados en la semana pasada y no en esta indican que se está yendo.

Del otro lado, lo que más protege es tener muchos días activos, con −0.633, haber viajado en la última semana, con −0.519, y no estar en el padrón, con −0.312. En el corte A abandona el 11.3% de quienes no están en el padrón, contra entre 12.2% y 17.5% de los que sí tienen un perfil registrado.