Ing. Max Cerna

Ciencia de Datos

Segundo semestre 2026

Universidad Rafael Landívar

Tradición Jesuita en Guatemala

Proyecto 2

¿Quién deja de usar la red?

José Daniel Paz Ortega, 1200022

Jonathan García, 1045222

La pregunta

- Con lo que sabemos de una persona hasta hoy, qué tan probable es que deje de usar la red en los próximos 30 días.
- Con esa probabilidad, a quién conviene contactar si la campaña no alcanza para todos.
- El corte es a las 00:00. Las features usan los 28 días antes y la etiqueta los 30 días después.
- Usamos tres cortes con el mismo código: A del 1 de julio para entrenar, B del 31 de julio como test único y C del 30 de agosto para entregar.
- Los datos son simulados.

Carga desde cero con un solo comando

```
python orquestacion/flow_prefect.py --desde-cero
```

- Borra el lake y el warehouse y vuelve a cargar todo con el pipeline del Proyecto 1.
- Los 9 archivos llegan a Bronze con las mismas filas que dice el LEEME.
- A Silver solo le agregamos una tabla con todo el padrón y el número de la persona.
- Tarda entre 25 y 67 segundos según la máquina.

Archivo	Esperadas	Cargadas
Transurbano	1,635,788	1,635,788
Transmetro	713,786	713,786
MetroRiel	590,844	590,844
Aerómetro	387,053	387,053
Padrón	77,636	77,636
4 catálogos	468	468

Unidad, población y etiqueta

- La unidad es la persona. El número de la tarjeta une Transmetro, Transurbano y MetroRiel. Aerómetro queda aparte.
- Entra quien tiene al menos 2 abordajes en los 28 días antes y no fue dado de baja en el padrón.
- La etiqueta es 1 si no viaja en ningún operador en los 30 días siguientes.

Corte	Población	Positivos	Tasa
A, 1 de julio	59,491	7,095	0.1193
B, 31 de julio	58,113	6,387	0.1099
C, 30 de agosto	57,701	oculta	oculta

Si usáramos la tarjeta, 2,404 de 10,812 abandonos serían personas que siguieron viajando con otra tarjeta. Con la persona, 1,460 de 7,095 positivos son solo de Aerómetro y no se pueden verificar.

Features y revisión de fugas

- 19 features de los 28 días antes del corte: recencia, frecuencia, tendencia, operadores, horario, gasto y perfil.
- Todas salen de Silver, así que lo que está en cuarentena no entra.
- Prueba de recorte en el corte A: calculamos las features con todos los datos y con los datos cortados al 30 de junio.
  - Recortando Silver salieron 0 diferencias en 59,491 personas.
  - Recortando los archivos originales y corriendo todo el pipeline en una copia aparte también salieron 0 diferencias.
- Ensayamos la invariancia con el corte B: con y sin los 30 días siguientes las predicciones salieron idénticas.

Modelos comparados con PR-AUC

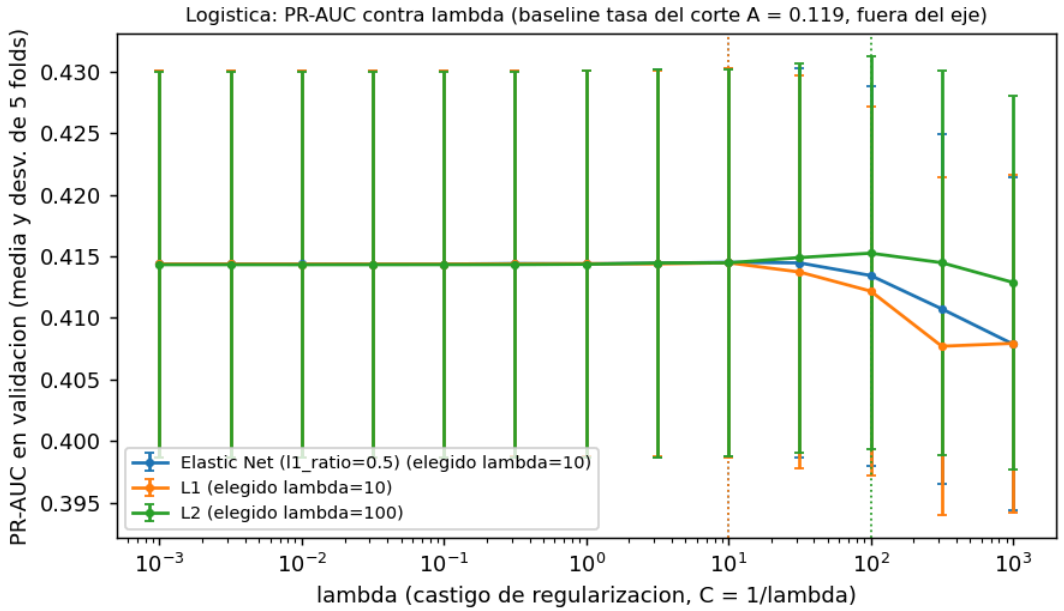
Modelo	Entrenamiento	Validación
Tasa del corte A	0.119	0.119
Días desde el último viaje	0.402	0.403
Menos viajes en 28 días	0.254	0.254
Logística L2, λ = 100	0.416	0.415
Logística L1, λ = 10	0.415	0.414
Logística Elastic Net, λ = 10	0.415	0.415
HistGradientBoosting	0.544	0.426
Random Forest	0.533	0.424

Mismos 5 folds del corte A para todos.

Usamos PR-AUC porque solo abandona el 12% y la Agencia va a contactar a los primeros de la lista. Mide qué tan arriba quedan los que se van y no se infla con los negativos fáciles. Su piso es la tasa, 0.119.

Solo con los días sin viajar ya se llega a 0.403. La logística apenas le gana y el boosting gana en los 5 folds.

Regresión logística



Lo que más sube el riesgo, con variables escaladas:

Feature	Coeficiente
Días desde el último viaje	+0.76
Viajes en 28 días	+0.33
Perfil general	+0.23
Perfil estudiante	+0.10
Viajes en 14 días	+0.09

Lo que más lo baja son los días activos, con −0.63, y los viajes de la última semana, con −0.52.

Sesgo, varianza y modelo elegido

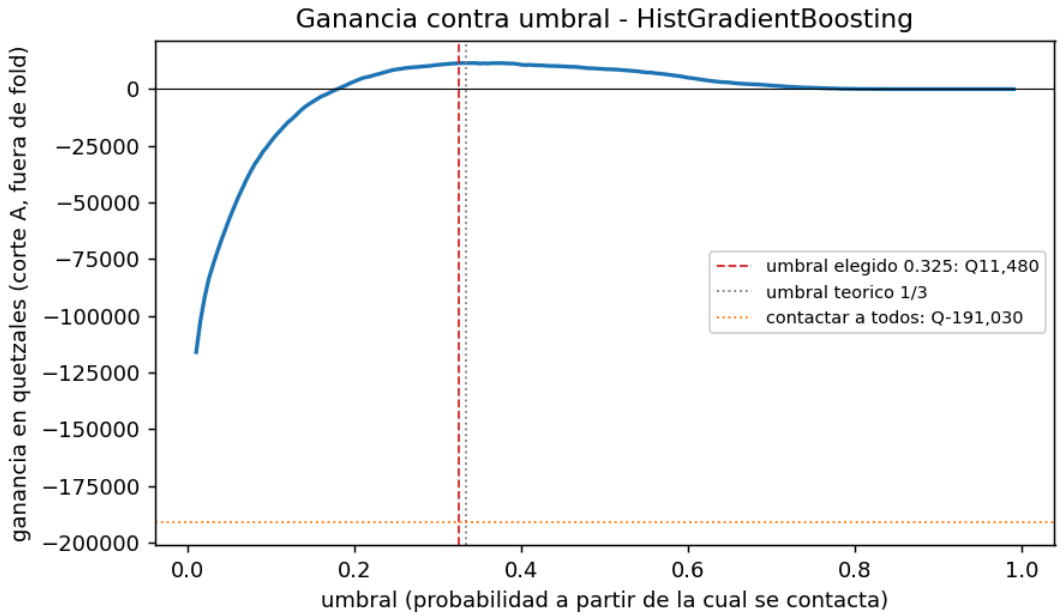
- Las líneas base y la logística tienen sesgo alto: sacan lo mismo en entrenamiento y validación.
- El boosting y el Random Forest tienen varianza moderada, con una brecha de 0.11 a 0.12, pero la mejor validación.
- Elegimos el boosting. Gana en los 5 folds y deja Q11,480 contra Q11,015 de la logística. Entrena en 2 segundos.

Importancia por permutación en validación:

Feature	Baja en PR-AUC
Días desde el último viaje	0.246
Perfil	0.015
Tendencia en 14 días	0.010
Viajes en 14 días	0.009
Viajes en 7 días	0.008

Umbral según el costo

- Contactar cuesta Q5, la campaña retiene al 25% de los que se iban y cada retenido vale Q60.
- Acertar deja 0.25 por 60 menos 5, que son Q10. Contactar a quien no se iba cuesta Q5.
- G = 10 × VP − 5 × FP
- En teoría conviene contactar si p es mayor que 1/3.
- En el corte A el mejor umbral fue 0.325, con 6,320 contactos y Q11,480.
- Contactar a todos perdería Q191,030.



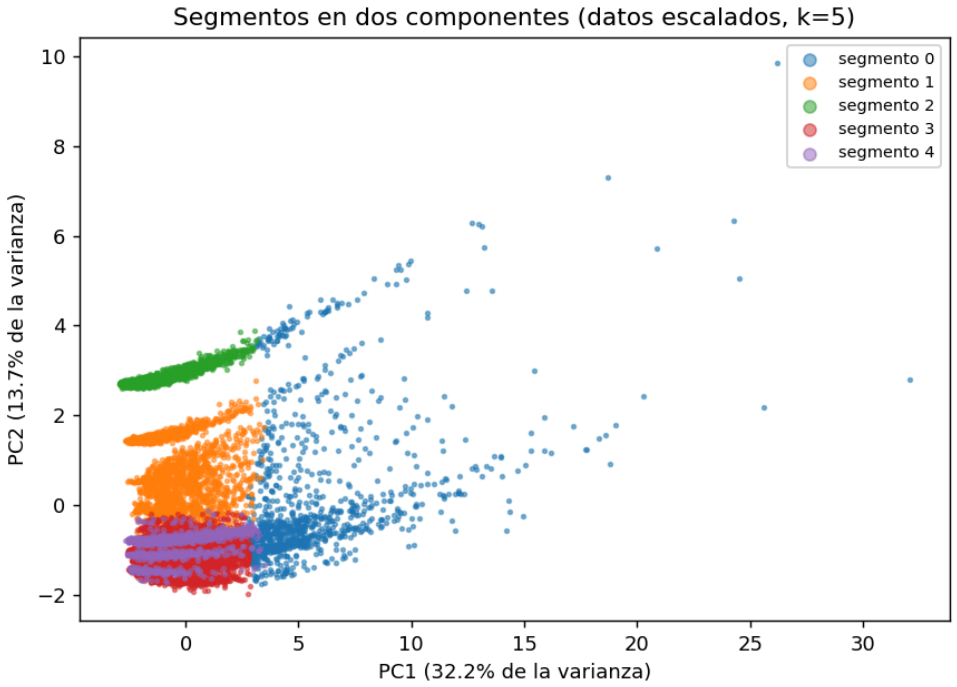
Test único en el corte B

	Validación A	Test B
PR-AUC del boosting	0.426	0.386
Línea base de recencia	0.403	0.359
Línea base de la tasa	0.119	0.110
ROC-AUC	0.841	0.839
Ganancia	Q11,480	Q7,550

Lo corrimos una vez el 3 de noviembre, en el commit 3a6bb7c. El script no deja correrlo otra vez.

- Baja porque en B abandona menos gente, 11.0% contra 11.9%, y la PR-AUC y la ganancia dependen de esa tasa.
- La ROC-AUC casi no cambia, así que el orden se mantiene.
- Contra la recencia el modelo gana por más en B que en validación.
- No ajustamos nada después de verlo.

Segmentos con KMeans y PCA



Segmento	Personas	Abandono
Viajeros intensivos	5,461	0.019
Usuarios de MetroRiel	10,082	0.125
Usuarios de Aerómetro	10,028	0.145
Usuarios de Transurbano	25,482	0.118
Usuarios de Transmetro	8,438	0.149

Elegimos k = 5 porque es el segundo pico de silueta y ahí se aplana el codo. Con k = 2 solo se separaban los intensivos. Las dos componentes explican el 45.9%.

Acciones: recarga condicionada para Transmetro, transbordo gratis para Aerómetro, pase semanal para MetroRiel y nada de presupuesto para los intensivos.

Puesta en producción

```
python predecir.py --datos datos_red --fecha-corte 2026-08-30
```

- Carga los datos, calcula las features, usa el modelo guardado y no reentrena.
- En el corte C evaluó a 57,701 personas y recomienda contactar a 7,872.
- Versiones fijas en requirements.txt, semilla 42 y ficha del modelo de una página.
- Al ensayar la invariancia vimos que dos corridas iguales daban 2,759 puntajes distintos. DuckDB suma en paralelo y las tarifas con decimales cambiaban en el último decimal. Lo corregimos sumando en centavos enteros, sin reentrenar ni tocar B, y ahora tres corridas dan el mismo archivo.

Limitaciones y conclusión

- El enlace entre tarjetas es un supuesto y Aerómetro no se puede enlazar.
- Casi toda la señal está en los días sin viajar, el modelo mejora poco sobre eso.
- Se entrenó con un solo mes, así que no vio temporadas ni cambios de tarifa.
- El 25% de retención es un supuesto del escenario.
- Con el umbral de costo, contactar a unas 7,900 personas en el corte C deja ganancia en lugar de la pérdida de contactar a todos, y conviene empezar por Transmetro y Aerómetro.