¿Quién deja de usar la red?

Proyecto 2 · Agencia Metropolitana de Transporte

Ciencia de Datos · Universidad Rafael Landívar · segundo semestre 2026

Daniel Paz (1200022) · Jonathan García (1045222)

Los datos son simulados: no corresponden a ningún operador ni usuario real.

La pregunta

- Con lo que sabemos de una persona hasta hoy, ¿qué tan probable es que deje de usar la red en los próximos 30 días?
- Con esa probabilidad, ¿a quién conviene contactar si la campaña no alcanza para todos?
- Clasificación binaria por persona y fecha de corte. Corte t = 00:00 hora local.
- Features: lo que pasó en los 28 días antes de t. Etiqueta: si viajó o no en los 30 días desde t.
- Tres cortes con el mismo código: **A** (1 jul) para entrenar y ajustar, **B** (31 jul) como test único, **C** (30 ago) para entregar.

Datos nuevos desde cero, con un solo comando

```
python orquestacion/flow_prefect.py --desde-cero
```

- Vacía el lake, el warehouse y los artefactos de dbt, y carga el pipeline del Proyecto 1 sin reestructurarlo.
- Los 9 archivos llegan a Bronze con exactamente las filas del LEEME: diferencia 0 en los nueve.
- Agregamos a Silver un solo modelo: todo el CDC con la llave de la persona.

Archivo	Esperadas	Cargadas
transurbano_transacciones	1,635,788	1,635,788
transmetro_validaciones	713,786	713,786
metroriel_viajes	590,844	590,844
aerometro_boardings	387,053	387,053
cdc_padron_usuarios	77,636	77,636
4 catálogos	468	468

Carga completa: entre 25 y 67 segundos según la máquina.

Unidad, población y etiqueta

- **Unidad: la persona.** El número dentro de la tarjeta enlaza Transmetro, Transurbano y MetroRiel (supuesto del Proyecto 1). Aerómetro queda aparte.
- **Población:** ≥ 2 abordajes válidos en los 28 días previos y sin DELETE vigente en el CDC.
- **Etiqueta 1:** ningún abordaje válido, en ningún operador, en los 30 días desde el corte.

Corte	Población	Positivos	Tasa
A · 1 jul	59,491	7,095	0.1193
B · 31 jul	58,113	6,387	0.1099
C · 30 ago	57,701	etiqueta oculta	

Costo de la unidad. Con la tarjeta, 2,404 de 10,812 positivos (0.22) serían personas que siguieron viajando con otra tarjeta. Con la persona, 1,460 de 7,095 positivos (0.21) son solo de Aerómetro y no se pueden verificar.

Features y auditoría de fuga

- 19 features con ventana de 28 días, iguales en los tres cortes: recencia, frecuencia, tendencia, mezcla de operadores, horario, gasto y perfil del padrón.
- Salen solo de Silver: lo que está en cuarentena no entra.
- **Prueba de recorte** del corte A, datos completos contra datos recortados al 30 de junio:
  - Recortando Silver: 59,491 filas, **0 diferencias**.
  - Recortando los archivos crudos y corriendo todo el pipeline en una copia aislada: **0 diferencias**.
- **Invariancia ensayada** con el corte B: predicciones con los datos hasta el 31 de julio contra datos con 30 días más, archivos idénticos byte por byte.

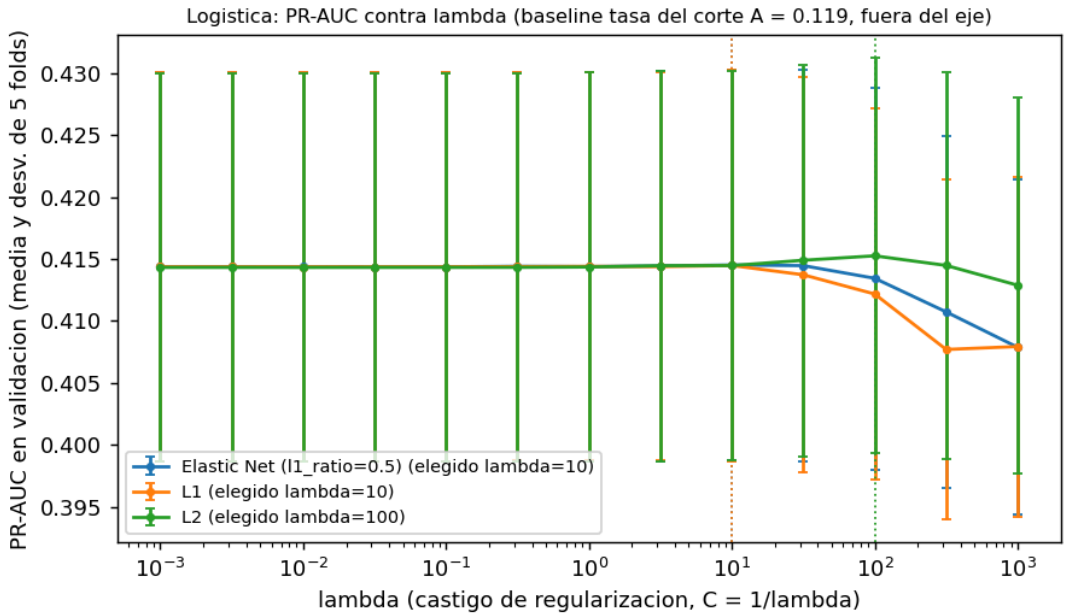
Modelos: mismos 5 folds del corte A, métrica PR-AUC

Modelo	Entren.	Validación
Baseline: tasa del corte A	0.119	0.119 ± 0.000
Baseline: días desde el último viaje	0.402	0.403 ± 0.014
Baseline: menos viajes en 28 días	0.254	0.254 ± 0.004
Logística L2, λ = 100	0.416	0.415 ± 0.016
Logística L1, λ = 10	0.415	0.414 ± 0.016
Logística Elastic Net, λ = 10	0.415	0.415 ± 0.016
HistGradientBoosting	0.544	**0.426 ± 0.015**
Random Forest	0.533	0.424 ± 0.014

¿Por qué PR-AUC? Solo el 12% abandona y la Agencia contacta a los de arriba de la lista. La PR-AUC mide qué tan arriba quedan los que se van y no se infla con miles de negativos fáciles. Su piso es la tasa: 0.119.

Lectura: la recencia sola ya da 0.403. La logística apenas le gana; el boosting gana en los 5 folds.

Logística: λ y coeficientes



Los que más empujan hacia el abandono (variables escaladas):

Feature	Coef.
días desde el último viaje	+0.76
viajes en 28 días (con los recientes fijos = caída)	+0.33
perfil general	+0.23
perfil estudiante	+0.10
viajes en 14 días	+0.09

Protegen: días activos (−0.63) y viajes en la última semana (−0.52).

Sesgo-varianza y modelo para producción

- **Baselines y logística:** sesgo alto. Entrenamiento ≈ validación; la frontera lineal no capta más.
- **Boosting y Random Forest:** varianza moderada (brecha 0.11 a 0.12), pero la mejor validación.
- **Decisión: boosting.** Gana en los 5 folds (+0.007 a +0.016) y deja Q11,480 contra Q11,015. Entrena en 2 s y se guarda en un archivo.

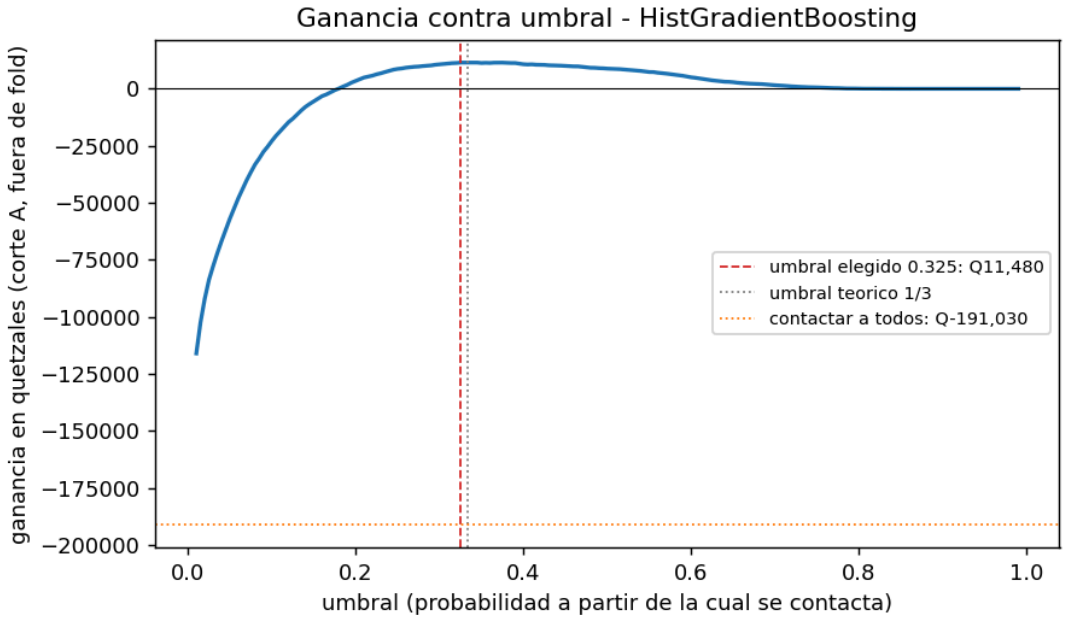
Importancia por permutación, en validación:

Feature	Caída de PR-AUC
días desde el último viaje	0.246
perfil	0.015
tendencia 14 días	0.010
viajes en 14 días	0.009
viajes en 7 días	0.008

Umbral según el costo

Contactar cuesta Q5; la campaña retiene al 25% de quienes se iban; un retenido vale Q60.

- Acertar: 0.25 × 60 − 5 = **+Q10**
- Contactar a quien no se iba: **−Q5**
- **G = 10 × VP − 5 × FP**
- Teoría: contactar si p > 5/15 = 1/3
- Elegido en A (fuera de fold): **0.325**, con 6,320 contactos y **Q11,480**
- Contactar a todos: −Q191,030



Test único en el corte B

3 de noviembre de 2026, commit 3a6bb7c. El script se niega a correr dos veces.

	Validación A	Test B
PR-AUC boosting	0.426	**0.386**
Baseline recencia	0.403	0.359
Baseline tasa	0.119	0.110
ROC-AUC	0.841	0.839
Ganancia	Q11,480	**Q7,550**

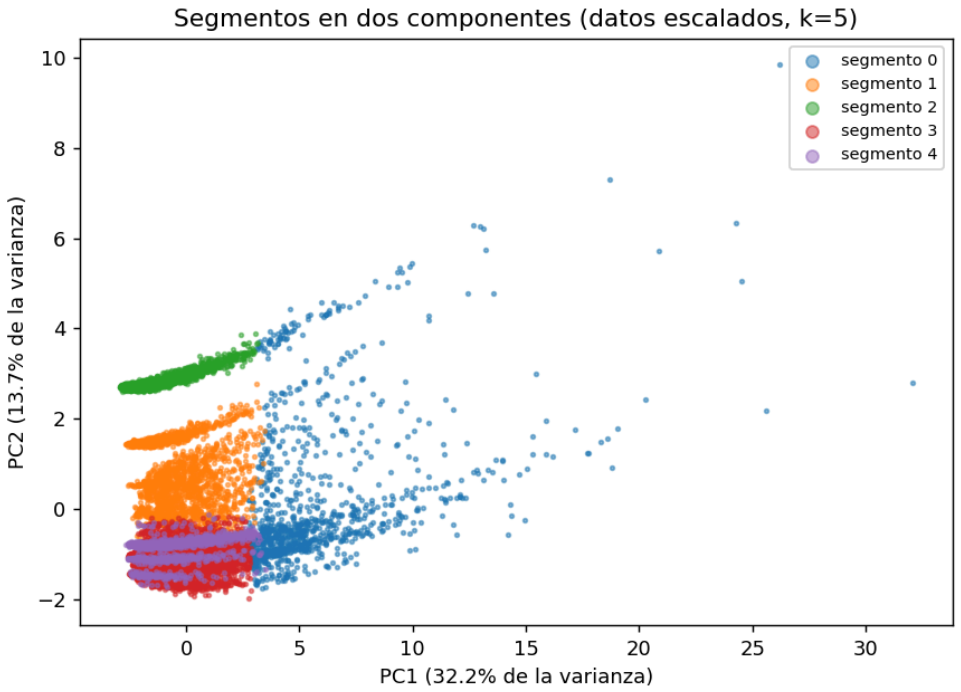
Matriz en B: VP 2,746 · FP 3,982 · FN 3,641 · VN 47,744.

¿Por qué baja? En B abandona menos gente (11.0% contra 11.9%). La PR-AUC y la ganancia dependen de esa tasa.

El orden se mantiene: la ROC-AUC casi no cambia y el modelo le gana a la recencia por más en B (+0.027) que en validación (+0.023).

No ajustamos nada después de verlo.

Segmentos: KMeans (k = 5) y PCA



Segmento	Personas	Abandono
Viajeros intensivos	5,461	0.019
Usuarios de MetroRiel	10,082	0.125
Usuarios de Aerómetro	10,028	0.145
Usuarios de Transurbano	25,482	0.118
Usuarios de Transmetro	8,438	0.149

k = 5: segundo pico de silueta (0.249) donde se aplana el codo; k = 2 solo separaba a los intensivos. PCA: 45.9% de la varianza.

Acciones: Transmetro, recarga condicionada a volver a viajar. Aerómetro, transbordo sin costo a otro modo. MetroRiel, pase semanal. Intensivos, no gastar en ellos. La tasa es descriptiva, no causal.

Producción

- `python predecir.py --datos datos_red --fecha-corte 2026-08-30` carga los datos, calcula las features, carga `modelos/modelo_abandono_v1.joblib` y no reentrena.
- Corte C: **57,701 personas, 7,872 a contactar**, en `predicciones/predicciones_2026-08-30.csv`.
- Versiones fijas en requirements.txt, semilla 42, ficha del modelo de una página.
- **Lo que encontramos al ensayar la invariancia:** dos corridas iguales daban 2,759 puntajes distintos. DuckDB suma en paralelo y las tarifas decimales cambiaban en el último decimal; el boosting lo convertía en otro intervalo. Lo corregimos sumando en centavos enteros, sin reentrenar ni volver a tocar B. Ahora tres corridas dan el mismo archivo.

Limitaciones y conclusión

- El vínculo entre tarjetas es un supuesto, y Aerómetro no se puede enlazar.
- Casi toda la señal está en la recencia: el modelo mejora, pero poco, sobre "días sin viajar".
- Entrenado con un solo mes: no vio estacionalidad ni cambios de tarifa.
- El 25% de retención es un supuesto del escenario, no algo medido.
- **Conclusión:** con el umbral de costo, contactar a ~7,900 personas en el corte C deja una ganancia positiva en lugar de la pérdida de contactar a todos, y la Agencia puede priorizar Transmetro y Aerómetro.